

# Trabalho de Conclusão de Curso

Desenvolvimento de um Sistema de  
Calibração de Cores com  
Reconhecimento de Objetos para a  
Equipe de Futebol De Robôs Cedro  
Categoria IEEE Very Small Size

Jasane Schio

Orientação: Prof. Dr. Gedson Faria

Área de Concentração: Sistemas de Informação, Visão Computacional

Sistema de Informação  
Universidade Federal de Mato Grosso do Sul  
30 de Setembro de 2015

Desenvolvimento de um Sistema de  
Calibração de Cores com  
Reconhecimento de Objetos para a  
Equipe de Futebol De Robôs Cedro  
Categoria IEEE Very Small Size

Coxim, 01 de Outubro de 2015.

Banca Examinadora:

- Prof. Me. Angelo Darcy (CPCX/UFMS)
- Prof. Dr. Gedson Faria (CPCX/UFMS) - Orientador

# Conteúdo

<b>Lista de Figuras</b>	<b>5</b>
<b>1 Introdução</b>	<b>6</b>
1.1 Justificativa . . . . .	7
1.2 Objetivos . . . . .	7
1.2.1 Objetivo Geral . . . . .	7
1.2.2 Objetivos Específicos . . . . .	7
<b>2 Fundamentação Teórica</b>	<b>8</b>
2.1 Processamento de Imagens . . . . .	8
2.1.1 Detecção de Objetos . . . . .	8
2.1.2 Detecção de Bordas . . . . .	9
2.2 Espaço e Modelo de Cores . . . . .	10
2.2.1 Espaços de Cores . . . . .	10
2.2.2 Modelo de Cores . . . . .	11
2.3 Linguagem de Programação e Bibliotecas . . . . .	14
2.4 Probabilidade e Estatística . . . . .	14
2.4.1 T de Student . . . . .	14
2.4.2 Graus de Liberdade . . . . .	15
2.4.3 Intervalos de Confiança . . . . .	15
2.5 Futebol de Robôs . . . . .	16
2.6 Trabalhos Relacionados . . . . .	16
2.6.1 Calibra . . . . .	16
2.6.2 VSS-Vision . . . . .	17
<b>3 Metodologia e Desenvolvimento</b>	<b>19</b>

3.1	Projeto . . . . .	19
3.1.1	Organização do Projeto . . . . .	19
3.1.2	Classes . . . . .	21
3.2	Fluxo do Sistema . . . . .	21
3.2.1	Fluxo de Calibração Manual . . . . .	22
3.2.2	Fluxo de Calibração Automatica . . . . .	22
<b>4</b>	<b>Aplicativo</b>	<b>26</b>
4.1	Tela Principal . . . . .	26
4.2	Seleção do Objeto Colorido . . . . .	27
4.3	Geração de Gráfico . . . . .	27
4.4	Seleção de Minimos e Maximos . . . . .	28
4.5	Arquivo Final . . . . .	28
<b>5</b>	<b>Primeiros Resultados - Seleção Manual de Mínimos e Máximos</b>	<b>29</b>
	<b>Referências Bibliográficas</b>	<b>30</b>
	<b>Apêndices</b>	<b>31</b>

# **Lista de Figuras**

2.1	Exemplo dos espaços de cores RGB E CMY. . . . .	11
2.2	Exemplo do Modelo de Cor RGB. Horvath(2) . . . . .	12
2.3	Exemplo do Modelo de Cor HSV(a) e HSL(b). Horvath(2) . . . . .	13
2.4	Exemplo do Modelo de Cor HPG. Mendes (3) . . . . .	13
2.5	Distribuição de Student(t) para valores de v. Spiegel (4) . . . . .	15
2.6	Sistema Calibra desenvolvido pelo Centro Universitário da FEI (5) . . . . .	17
2.7	Sistema de calibracao desenvolvido peloSIRLab (6) . . . . .	17
2.8	Sistema de calibracao desenvolvido peloSIRLab (7) . . . . .	18
3.1	Organização das pastas do projeto . . . . .	20
3.2	Diagrama de Classes do projeto . . . . .	20
3.3	Diagrama de Fluxo . . . . .	21
3.4	Diagrama de Fluxo Manual . . . . .	22
3.5	Diagrama de Fluxo Automatico . . . . .	23
4.1	Janelas do Sistema: Janela 1 e Janela 2 . . . . .	26
4.2	A seleção do ponto com a cor, é obtido pela interação do usuário. . . . .	27
4.3	Gráfico gerado após seleção dos pontos de cor. . . . .	27
4.4	Gráfico apóis escolhas de mínimos e máximos. . . . .	28
4.5	Arquivo com minimo e máximo dos valores HSV para cada cor. . . . .	28
5.1	Threshold gerado apos seleção manual. . . . .	29

# Capítulo 1

## Introdução

Avanços tecnológicos tentam a cada dia mais dar vida as máquinas aplicando sentidos e percepções que se assemelham as humanas. Dentre estes, Inteligência Artificial, Aprendizado de Máquina, processamento de áudio, processamento de imagem entre outros. Segundo Albuquerque(8) processar uma imagem, da mesma maneira que o nosso sistema visual humano é capaz de fazer é extremamente complexo, realizar as mesmas tarefas com a ajuda de máquinas, exige por antecedência uma compreensão “filosófica” do mundo ou dos conhecimentos humanos. Sem esse conhecimento pré existente por parte da máquina, a interpretação de uma imagem e seu processamento se baseia nas informações contidas na mesma.

Essa obtenção e entendimento das informações contidas na imagem se dá pela Visão Computacional, o ramo encarregado por simular o sistema visual humano. O que é feito de uma maneira única pelo sentido humano é separado em varias tarefas dentro da Visão Computacional com a captura de imagem, seu processamento, aquisição de informações da mesma, processamento dessa informação e aplicação de parâmetros para classificação da informação entre outros. Gonzalez(9) descreve que uma imagem digital é composta por um número finito de elementos, cada um dos quais tem um determinado local e valor, assim o Processamento de Imagem Digital tem como tarefa a retirada de informações dos elementos de uma imagem.

Dentre tipos de processamento de imagens existem, Gonzalez(9) os define como: aplicações de ações primitivas de modificação de imagem, esta caracterizada por seu resultado final ser também uma imagem semelhante a imagem inicial porém modificada (Low-Level-Process), divisão de imagem em regiões e alguns tipos de reconhecimento e classificação de objetos, caracterizada por seu resultado final ser muitas vezes apenas regiões ou informações da imagem inicial (Mid-Level-Process), e o mais “sensorial” de todos que é a analise de objetos usando funções cognitivas associadas a visão computacional, essa usa informações relevantes para o reconhecimento de objetos (Higher-Level-Process).

Neste trabalho propõe-se o a automatização do processo de detecção de objetos desenvolvendo um sistema de calibração de intervalo de Mínimos e Máximos dos valores HSV de cores para ser usado pela equipe de Futebol de Robôs Cedro, categoria Very Small Size. Valores HSV são um dos tipos de valores usados para definir as cores em computação, esses valores são correspondentemente Hue, a cor pura, Saturation, o grau de pureza da cor, e Lightness, que é o luminosidade aplicada. No sistema além da detecção automática estará também disponível a detecção manual de objetos.

## 1.1 Justificativa

- A falta, na equipe, de um sistema de fácil manuseio para detecção de valores HSV
- A falta, na equipe, de um sistema automático de registro do valores HSV mínimos e máximos
- A falta, na equipe, de um sistema que defina mínimos e máximos de forma automática, baseando-se nos objetos escolhidos
- A falta, na equipe, de um sistema autônomo de calibração de intervalo de cores
- Aplicação do sistema proposto na identificação de robôs moveis em times de futebol de robôs.

## 1.2 Objetivos

### 1.2.1 Objetivo Geral

Este trabalho tem por objetivo principal automatizar o sistema de identificação de objetos coloridos em imagens provenientes de uma câmera em tempo real, fazendo a calibração de intervalo de Mínimos e Máximos dos valores HSV. Para alcançar o objetivo principal, foram propostos os seguintes objetivos específicos.

### 1.2.2 Objetivos Específicos

- Implementar uma interface que conte com disposição de informações no estilo gráfico ou histograma de cores para um corte manual de valores visando diminuição da velocidade de detecção;
- Estudo e implementação de um sistema inteligente de calibração de cores e no corte inteligente de valores minimo e máximo das cores
- Testar o sistema proposto para identificação de equipes e participantes do futebol de robô na categoria Very Small Size.

# **Capítulo 2**

## **Fundamentação Teórica**

### **2.1 Processamento de Imagens**

#### **2.1.1 Detecção de Objetos**

Antes de descrever os métodos de classificação devemos fazer algumas definições:

- Em cada detecção de objetos são obtidas as informações sobre a imagem, essas são de acordo com o tipo de detecção desejada. Os dados podem conter informações como posição, tamanho, borda, transformação linear, rotação entre outros. Cada detecção em uma imagem é chamada de pose.
- Métodos de detecção de objeto baseado em classes constroem a classe do objeto baseada em um conjunto de treino. O conjunto de treino é composto por múltiplas imagens exemplo do objeto para que seja assim capturado os aspectos do objeto.

A detecção de objetos pode ser considerada uma técnica herdada do reconhecimento de padrões da área de aprendizado de máquina, esta consiste em separar objetos por categorias de acordo com uma ou mais características específicas. Quando essa técnica se junta ao processamento de imagens, onde são acentuadas as características específicas do objeto dentro da imagem para assim este se destacar, tornou-se possível a detecção de objetos em imagens que dentro do campo de visão computacional é uma das áreas que mais obtêm a atenção de pesquisadores. O primeiro Framework de métodos que usam base de dados categorizando uma ou mais características de um objetos para fazer o reconhecimento através de aprendizado foi apresentado em 2001 por Viola e Jones(10). Desde o framework de Viola e Jones até os dias atuais muitos métodos e teorias para detecção já foram propostos e implementados como detecção de faces utilizando um classificador de redes neurais na intensidade de padrões de uma imagem, support vector machine para localizar rostos humanos e carros(11), análise de componentes principais, análise independente de componentes, fatoração de matriz não-negativa, análise discriminativa linear, boosting(12), além da classificação binária, onde se considera a detecção do objeto em tamanho fixo apenas variando na posição na imagem(13).

Em 2005 Ulusoy e Bishop(14) mostraram o quanto útil seria categorizar os métodos de detecção de imagens, e os dividiram em duas principais categorias: generativa e discriminativa.

Categorias que foram aceitas e utilizadas como mostram Amit e Felzenszwalb(13) e Roth e Winter(12).

O método generativo pode ser descrito como um modelo probabilístico para a variância da pose de um objeto juntando com o modelo de aparência, ou seja, um modelo de probabilidade para a aparência da imagem condicional em uma determinada pose, juntamento com um modelo de fundo. Os parâmetros do modelo são estimados a partir de dados retirados de treinamento e as decisões são baseadas nas probabilidades anteriores(13). Em resumo o método generativo tenta encontrar uma representação adequada dos dados originais através da aproximação dos dados originais, mas mantendo o máximo de informação possível(12).

Já o modelo discriminativo tipicamente constrói um classificador que pode discriminar entre imagens (ou sub-imagens) contendo o objeto e as que não contém o objeto. Os parâmetros do classificador são selecionados para minimizar os erros nos dados de treino(13).

Segundo Ulusoy e Bishop(14) o método generativo se destaca por tratar perda de dados ou dados parcialmente rotulados, pela facilidade em que uma nova classe pode ser incrementada na classificação condicional de densidade, independentemente das classes anteriores, e por conseguir facilmente lidar com composição de objetos (ex: óculos, chapéus...), considerando que os modelos discriminativos precisam analisar todas as combinações durante o treinamento. Amit e Felzenszwalb(13) ainda aponta que as vantagens descritas sobre o método discriminativo são ditas como a flexibilidade do modelo que pode ser utilizado em regiões do espaço de entrada onde as probabilidades posteriores diferem significativamente de 0 ou 1, ao passo que as abordagens detalhes generativas modelo de distribuição de X, que podem ser irrelevantes para determinar as probabilidades posteriores, além de ser tipicamente muito rápido em fazer previsões para os novos pontos (teste) de dados, enquanto os modelos generativos muitas vezes exigem solução iterativa, e pela igualdade de circunstâncias, seria de esperar que os métodos discriminativos tenham melhor desempenho preditivo, uma vez que são treinados para prever o rótulo de classe em vez de a distribuição conjunta de vetores e alvos de entrada.

### 2.1.2 Detecção de Bordas

Para um objeto poder ser detectado por algum método de detecção de objetos a imagem passa por um processo de segmentação. A segmentação pode ser dita como o processo de divisão da imagem em objetos(9). De acordo com Wangenheim(15) o processo de segmentação se baseia em dois conceitos: similaridade e descontinuidade. A descontinuidade é o processo onde se separa o fundo das partículas e estas umas das outras, através de linhas, bordas ou pontos. Já a similaridade é o processo onde os pixels provenientes da descontinuidade são agrupados de acordo com a proximidade um dos outros para formar os objetos de interesse. De acordo com Canny(16) o processo de detecção de bordas é um processo simplificado que serve para diminuir drasticamente o total de dados a serem processados e ao mesmo que o mesmo preserva informações valiosas sobre os objetos. É muito comum a ocorrência de ruídos quando se trata da detecção de bordas, e por sua vez para evitar esses ruídos é necessário a suavização da imagem antes de fazer a detecção. Vale(17) lembra que a suavização possui pontos negativos como perda de informação e deslocamento de estruturas de feições proeminentes no plano da imagem. Além disso, existem diferenças entre as propriedades dos operadores diferenciais comumente utilizados, o que ocasiona bordas diferentes. Assim, como dito por Ziou e Tabbone citados por Vale(17), se torna difícil encontrar um algoritmo que

tenha bom desempenho em diferenciados contextos e capture os requisitos necessários aos estágios subsequentes do processamento. Quando se trata de detecção de bordas existem dois critérios(16) para essa detecção que devem ser levados em consideração, Taxa de Erro e Localização(17).

**Taxa de Erro** É importante que as bordas contidas na imagem não sejam confundidas ou perdidas e ainda que não sejam detectadas bordas falsas. É necessário que o algoritmo de detecção de borda tenha uma baixa taxa de erro para que seja eficiente.(15, 16, 17)

**Localização** A distância entre os pixels de borda encontradas pelo algoritmo e a borda atual deveriam ser o menor possível.(15)

Ao tentar aplicar esses dois critérios para desenvolver um modelo matemático para detecção de bordas sem a necessidade de base em regras preestabelecidas em seu artigo *A Computational Approach to Edge Detection* Canny percebeu que somente esses dois critérios não eram o suficiente para obter uma boa precisão da detecção de bordas. E então propôs um terceiro critério: Resposta.

**Resposta** Para contornar a possibilidade de mais de uma resposta para a mesma borda, ou seja o detector de bordas não deveria identificar múltiplos pixels de borda onde somente exista um único pixel. (15, 16, 17)

Com o acréscimo do terceiro critério então nota-se que o processo de detecção de bordas de Canny mostrou-se bastante flexível, independente da origem da imagem utilizada(17).

## 2.2 Espaço e Modelo de Cores

O olho humano é capaz de identificar cores mesmo com as mais diferentes interferências, luminosidade, tonalidade, intensidade, entre outras ações de agentes externos, pois nosso cérebro assimila a cor a sua aparência, já para uma máquina cores são números, códigos, cada cor contém um código específico e cada uma de suas variâncias e alterações também. Para o nosso cérebro é muito fácil entender, exemplo, que o verde, verde lima, verde escuro são a mesma cor, apenas com tonalidades diferentes, já para o computador estas são: (0,255,0),(50,205,50),(0,128,0), no padrão de cor RGB que considera uma luz visível. Mas se for aplicado luminosidade nessas cores, por exemplo, elas ainda se tornam outras diferentes cores, um código diferente para cada luminosidade possível. Para conseguir cobrir todas essas alterações nas cores foram definidos em 1921 começaram então pela Comissão Internacional de Iluminação (CEI) a serem definidos espaços e modelos de cores(18).

### 2.2.1 Espaços de Cores

Segundo Foley et. al citado por Souto(18) espaço de cores é um sistema tridimensional de coordenadas, onde cada eixo refere-se a uma cor primária. A quantidade de cor primária necessária para reproduzir uma determinada cor, é atribuída a um valor sobre o eixo correspondente. O espaço de cores pode ser entendido como a quantidade de detalhamento,

tonalidades de uma cor, dentro do espectro de cores de um determinado modelo de cor. Quando fez sua primeira experiência com a decomposição da luz em um prisma para obter cores Newton percebeu que não havia a cor branca. Ele tentou então misturar as sete cores que obteve para gerar a branca, sem sucesso. Para gerar a cor branca é necessário a soma das três cores primárias azul, verde e vermelho. Após anos de estudo entendeu-se que existe duas formas de se obter cores: através da emissão ou reflexão de luz, espaços RGB e CMY respectivamente, Figura 2.2.

## RGB

O espaço de cores que emitem luz é conhecido como RGB que é baseado na teoria das cores primárias vermelho, verde e azul, em inglês Red, Green, Blue, para simular a tricromática visão humana, onde toda cor é composta pela soma das três cores.

## CMY

O espaço de cores que refletem luz é conhecido como CMY que são as cores ciano, magenta e amarelo, em inglês Cyan, Magenta e Yellow. Neste espaço a cor é obtida pela subtração das cores. Existe uma variação ao CMY chamada de CMYK onde é acrescentada a cor preta e foi criado como uma opção mais barata, pois não necessita de pigmentos puros(19).

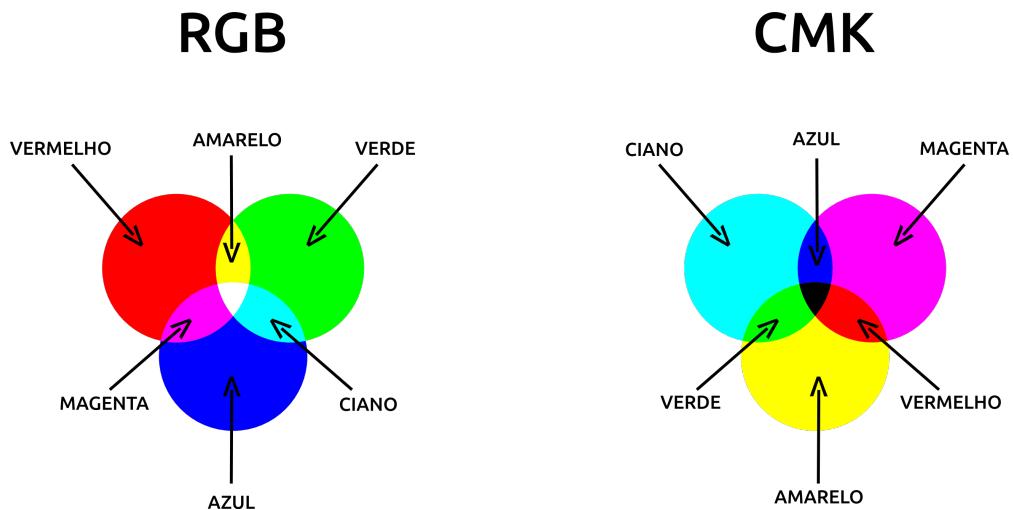


Figura 2.1: Exemplo dos espaços de cores RGB E CMY.

### 2.2.2 Modelo de Cores

Modelos de cores são modelos matemáticos utilizados para classificação das cores de acordo com sua tonalidade, saturação, luminosidade ou crominância na tentativa de conseguir cobrir o maior número de cores possíveis e assim simulando a visão. A representação da cor é definida por um único ponto em um modelo tridimensional.

## RGB

O modelo de cores RGB pode ser considerado mais básico dos modelos de cores. Seu nome possui a mesma definição do espaço de cores RGB. Ele não utiliza de nenhum atributo como luminosidade ou tonalidade, por exemplo, para a definição da cor apenas a adição das cores primárias, azul, verde e vermelho. É este também o padrão mais usado e conhecido. Os valores de R,G e B variam de 0 à 255.

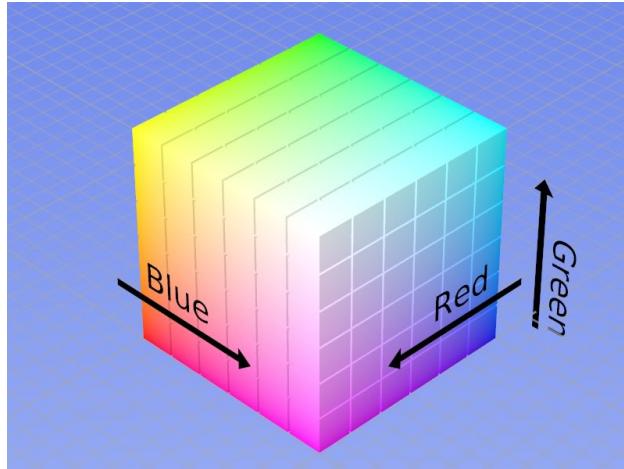


Figura 2.2: Exemplo do Modelo de Cor RGB. Horvath(2)

## HSL, HSB/HSV

Os modelos de cores tem função definir as cores nos programas gráficos de computadores de forma que combine com a percepção das cores pelo sistema visual humano e utilize três eixos similares para definirem a cor(20). O modelo HSL define tonalidade (hue) que é a cor em si, variando de 0 a  $360^\circ$ , saturação (saturation) que define o grau de pureza da cor, obtido pela mistura da tonalidade com a cor cinza, variando de 0 a 1, e luminosidade (lightness) é o brilho de um determinado objeto tendo o branco absoluto com referência. A luminosidade varia de escuro a claro tendo como limites definidos o preto e o branco(20), variando também de 0 a 1. O modelo HSV/HSB define tonalidade (hue) que é a cor em si, variando de 0 a  $360^\circ$ , saturação(saturation) que define o grau de pureza da cor, variando de 0 a 1, obtido pela mistura da tonalidade com a cor branca e brilho (value/brightness) que tenta fazer referência à percepção humana(20) que é a intensidade da cor, variando também de 0 a 1.

## HPG

O modelo de cores HPG foi proposto em 2007 pela Universidade Federal do Rio Grande do Norte estes partiram do princípio de que as cores podem ser definidas com uma mistura de cor pura e tom de cinza(21) e este é apropriado para aplicações onde seja necessário distinguir entre regiões de cor e regiões de cinza(3). O modelo define tonalidade (hue), pureza (purity) e cinzeamento (grayness). Neste modelo um pixel é definido como sendo composto por uma componente de cor pura e por uma componente de tom de cinza puro, ponderados por um

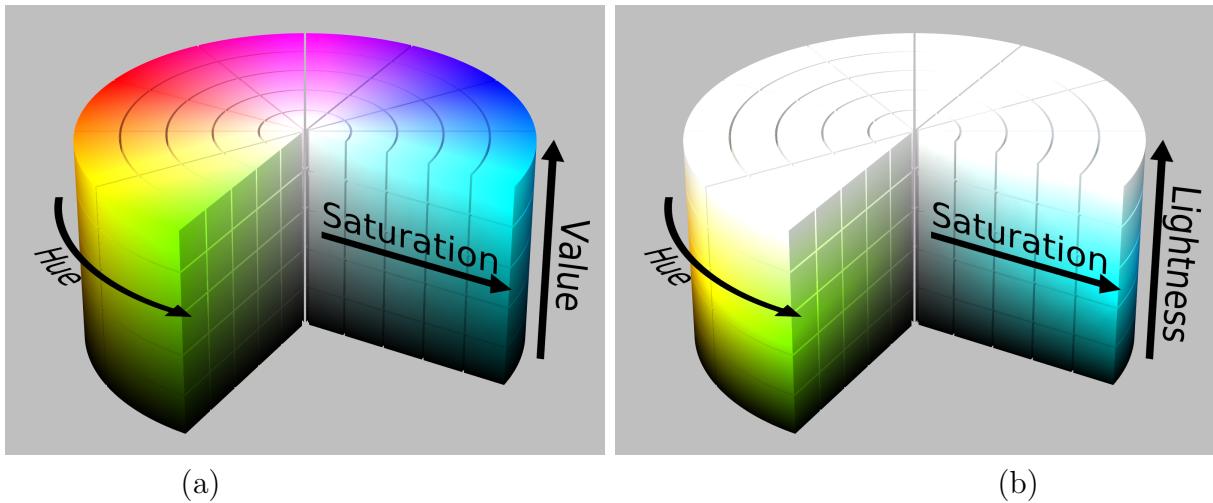


Figura 2.3: Exemplo do Modelo de Cor HSV(a) e HSL(b). Horvath(2)

fator de pureza(3). O modelo de cores HPG se baseia nos valores obtidos de cada pixel no modelo RGB e então é feito um calculo de conversão.

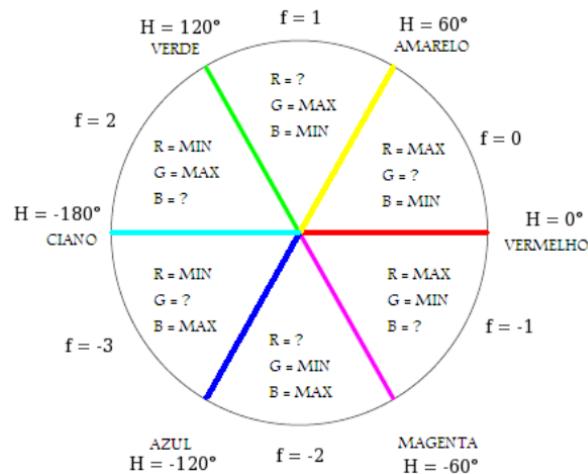


Figura 2.4: Exemplo do Modelo de Cor HPG. Mendes (3)

## 2.3 Linguagem de Programação e Bibliotecas

Para realização deste trabalho, irei utilizar a biblioteca de processamentos de imagens conhecida como OpenCV: Open Source Computer Vision Library. O trabalho será elaborado na linguagem C++, com uso do framework Qt para sua interface gráfica. Os passos detalhados do projeto e seu desenvolvimento estarão presente no Capítulo de Metodologia.

**OpenCV** Lançado em 1999 pela Intel(22), com objetivo de ser otimizada, portável e com um grande número de funções, o Open Source Computer Vision Library, OpenCV, se tornou uma ferramenta que possui mais de 2500 algoritmos e 40 mil pessoas em seu grupo de usuários(22). Já possui interface para as linguagens C++, C, Python e Java além de suporte para as principais plataformas com Windows, Linux, Mac OS, iOS e Android. A biblioteca lida tanto com imagens em tempo real, como vídeos e imagens estáticas.

**Qt** Qt é um framework de desenvolvimento de aplicações multiplataforma. Entre suas funcionalidades está a possibilidade de criar interfaces gráficas diretamente em C ++ usando seu módulo Widgets.

**C++** A linguagem de programação C++ foi projetado por Bjarne Stroustrup para fornecer eficiência e flexibilidade da linguagem C para programação de sistemas. A linguagem evoluiu a partir de uma versão anterior chamado C com Classes, o projeto C com Classes durou entre 1979 e 1983 e determinou os moldes para o C++. A linguagem foi oficialmente lancada em 1986.(23)

## 2.4 Probabilidade e Estatística

Para a automatização dos sistema de detecção de bordas e objetos foi utilizado a Distribuição T de Student para encontrar o valor de referencia  $t$  para encontrar a Tabela T(24) para assim calcular o valor do Intervalo de Confiança, usado para limitar o tamanho desejado dos objetos. Todas as definições dessa seção foram retidas do livro Estatística de Spiegel(4).

### 2.4.1 T de Student

Com a necessidade de manipular dados de pequenas amostras William Sealey Gosset com o pseudônimo de Student derivou o teste t de Student baseado na distribuição de probabilidades t, publicando esses estudos em 1908 na revista Biometrika(25). A teoria T de Student é um teoria usada em pequenas amostras, ou seja, amostras com tamanho menor que 30.

De acordo com Spiegel (4), a definição da distribuição de "Student" t é dada por:

$$t = \frac{\bar{X} - \mu}{s/\sqrt{N}} = \frac{\bar{X} - \mu}{\hat{s}/\sqrt{N}}$$

Considerando-se amostras de tamanho N, extraídas de uma população normal de média  $\mu$ , e, se para cada amostra cacular-se o valor de  $t$ , por meio da média amostral e  $\bar{X}$  e do desvio padrão s ou  $\hat{s}$ , pode-se obter a distribuição amostral de  $t$ .

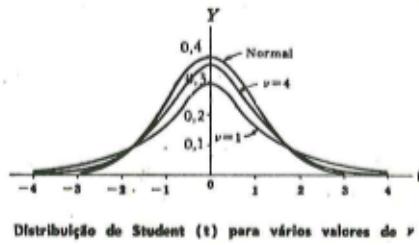


Figura 2.5: Distribuição de Student(t) para valores de v. Spiegel (4)

A distribuição (figura 2.5) é dada por:

$$Y = \frac{Y_0}{\left(1 + \frac{t^2}{N-1}\right)^{N/2}} = \frac{Y_0}{\left(1 + \frac{t^2}{\nu}\right)^{(\nu+1)/2}}$$

em que  $Y_0$  é uma constante que depende de N, de modo que a Área subentendida pela curva é igual a 1, e que a constante  $\nu = (N - 1)$  é denominada *número de graus de liberdade*  $\nu$ .

## 2.4.2 Graus de Liberdade

O numero de graus de liberdade é definido como o número N de observações independente da amostra, menos o numero  $k$  de parâmetros populacionais que devem ser estimados por meio das observações amostrais. Simbolicamente,  $\nu = N - k$ . O numero de graus de liberdade para a Distribuição T de Student é definida pelo número de observações independentes da amostra N, do qual podem ser calculados  $\bar{X}$  e  $s$ . Entretanto, como  $\mu$  deve ser avaliado,  $k = 1$ , então,  $\nu = N-1$ .

## 2.4.3 Intervalos de Confiança

A estimativa de parâmetro dada por dois números é denominada *estimativa por intervalo*, esta estimativa é considerada mais precisa e exata e assim é preferível à outras estimativas. Se a distribuição é aproximadamente normal pode se esperar que se encontre uma estatística amostral real, situada nos intervalos, assim pode-se esperar, ou estar confiante, de que o valor seja encontrado entre os intervalos, por esse motivo, esses intervalos são considerados intervalos de confiança. Para fazer o calculo dos Intervalos de Confiança é necessário escolher o *Nível de Confiança*, dados em percentagem e que ficam, na maioria dos casos, entre 95% e 99%.

Os limites do Intervalo de Confiança para médias, pode ser representado por:

$$\bar{X} \pm t_c \frac{s}{\sqrt{N-1}}$$

onde os valores, dos limites inicial e final,  $t_c$  são denominados *críticos* ou *coeficiente de confiança* e dependem do nível de confiança desejado e do tamanho da amostra. Valores retirados da Tabela T, neste trabalho foi usada para referencia a Tabela T da Universidade Federal Fluminense(24). Para os propósitos finais foi escolhido um nível de confiança de 95

## 2.5 Futebol de Robôs

Visto como um domínio bastante complexo, dinâmico e imprevisível(26), o futebol de robôs surgiu como uma tentativa de promover pesquisas nos campos de Inteligência Artificial e robótica, pela avaliação teórica, algoritmos e arquiteturas através dos problemas padrão(27). A Equipe Cedro se enquadra na categoria IEEE Very Small Size. Esta categoria é regulamentada pelo Instituto de Engenheiros Eletricistas e Eletrônicos (IEEE) e possui regras baseadas na MiroSot(6). O futebol de robôs se assemelha ao futebol humano onde o objetivo do jogo é fazer gols para vencer a partida, porém tendo regras adaptadas para o "ambiente" robótico. Rosa(6) em seu trabalho de graduação faz uma boa enumeração das regras básicas:

- A partida dura 10 minutos com dois tempos de 5 minutos;
- Há um intervalo de 10 minutos entre um tempo e outro;
- Cada time tem direito a dois tempos de 2 minutos que podem ser pedidos a qualquer momento;
- Caso a diferença de gols entre os dois times chegue a 10 a partida é encerrada;
- Uma falta ocorre quando há mais de um robô de um mesmo time dentro de sua própria área de gol ou quando um robô empurrar outro robô de outro time;
- Um pênalti ocorre quando a bola fica mais de 10 segundos dentro de alguma das áreas;
- Um chute-livre ocorre quando os robôs ficam travados por mais de 10 segundos, caso ocorra, o juiz posiciona a bola na marca de chute-livre mais próxima de onde ela ficou parada e posiciona os robôs de cada time equidistantes a bola;
- A cada início de partida ou gol feito a bola deve ser posicionada no centro do campo e os robôs devem ser posicionados de acordo com a posse de bola.

## 2.6 Trabalhos Relacionados

Para o tema específico deste trabalho, calibração de intervalos de cores para times de futebol de robôs da categoria very small size, não foram encontrados trabalhos relacionados, porém foram encontrados Team Description Papers e descrições de sistemas usados pelos times, onde consta sobre o processo de calibração e os métodos usados.

### 2.6.1 Calibra

O Centro Universitário da FEI, como visto em(28), utiliza em sua equipe Y04 uma solução desenvolvida denominada CALIBRA(5). Desenvolvida para sistemas Linux e com Graphical User Interface(5), o sistema de calibração possui um módulo chamado de MainWindow, que é responsável pela configuração de brilho, cor e contraste da imagem adquirida pela câmera e gera um arquivo que é analisado na hora da criação das cores padrão(28), onde cores-padrão são definidas como intervalos no espaço de cores HSI(28).



Figura 2.6: Sistema Calibra desenvolvido pelo Centro Universitário da FEI (5)

### 2.6.2 VSS-Vision

Desenvolvido inicialmente em Janeiro de 2016 pelo Laboratório de Sistemas Inteligentes de Robótica (SIRLab), utilizando para procesamento de imagens a biblioteca OpenCV e para telas interativas a biblioteca ImGui.

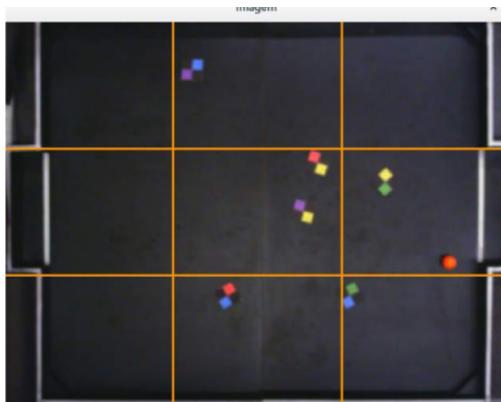


Figura 2.7: Sistema de calibracao desenvolvido peloSIRLab (6)

A rotina de calibração do VSS-Vision calibra laranja, amarelo e azul obrigatoriamente e as outras cores referentes aos jogadores em campo(6) de acordo com a escolha do time. A imagem é dividida em nove cantos, como visto na imagem 2.7, e para calibrar a cor o usuário deve clicar em cima da cor que gostaria de ser calibrada salvando um intervalo de cor tratado como RGB máximo daquela cor e o mínimo, a medida que vão havendo os cliques o sistema verifica para cada atributo se ele é maior que o atributo máximo salvo ou menor que mínimo salvo, caso seja, o mesmo assume o lugar de menor ou maior(6) e esse processo deve ser feito em cada um dos nove cantos da imagem. Os valores HSV encontrados são ajustados manualmente com a ajuda de sliders, como visto na imagem 2.8. Por conta de ser feita manualmente, a calibração dura de 5 a 10 minutos

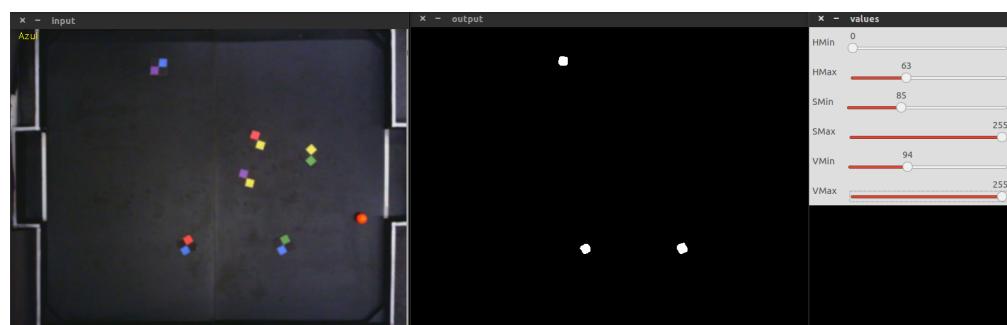


Figura 2.8: Sistema de calibracao desenvolvido peloSIRLab (7)

# Capítulo 3

## Metodologia e Desenvolvimento

Para o desenvolvimento foi escolhida a biblioteca OpenCV por ser OpenSource, multi-plataforma, uma grande quantidade de métodos e algoritmos já implementados e pelo seu rápido desempenho de máquina. A linguagem escolhida para o desenvolvimento foi o C++ pois é uma linguagem de programação compilada, o que torna sua execução mais rápida que as linguagens interpretadas, tendo assim grande desempenho e por ser uma linguagem orientada objeto.

O sistema desenvolvido é separado em duas partes: Processamento e Interface Gráfica. A parte de Processamento é onde são feitas as partes de aquisição de imagem, processamento de imagem, conversão de imagem para modelo de cor HSV, seleção de pontos de cor e contagem de ocorrência de cor. Já a interface gráfica, é a onde ocorre a entrada do usuário para assim ser feita a calibração manual de mínimos e máximos de cada cor.

Passos do projeto:

**Aquisição de imagens em vídeo:** Nesse passo as imagens são adquiridas via câmera USB.

**Identificação de Objetos:** Durante o processo de aquisição de imagem são selecionados os objetos, quais serão usados como base para a detecção de máximos e mínimos de cores.

**Cálculo de Mínimos e Máximos:** Nessa etapa são levados em consideração os objetos teste. A imagem é "varrida" por pixel na localidade dos objetos-teste e assim são salvos seus valores e feita a contagem de ocorrências de cada cor.

### 3.1 Projeto

#### 3.1.1 Organização do Projeto

O projeto foi desenvolvido seguindo o paradigma de programação conhecido como Orientação à Objetos, esse paradigma baseia-se na utilização de objetos individuais para criação de um sistema maior e complexo. A IDE usada para o desenvolvimento foi a QT Creator. Esta separada o projeto em três pastas, Headers, Sources e Forms. Na pasta Headers estão os arquivos de cabeçalho(.h) onde estão as declarações dos métodos e variáveis usados nas

classes executáveis. Já na pasta Sources estão os arquivos fonte(.cpp), são nesses arquivos que os métodos declarados nos arquivos da pasta Header são implementados. Na pasta Forms está o arquivo de interface gráfica(.ui) que é usado no projeto para ser a ponte entre o usuário e as funções do sistema.

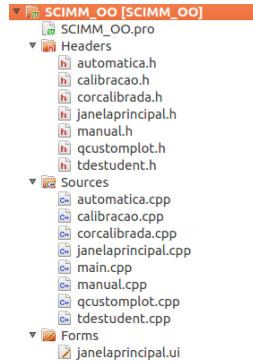


Figura 3.1: Organização das pastas do projeto

Cada arquivo de cabeçalho possui um arquivo fonte correspondente, formando assim uma Classe, com exceção do arquivo fonte main, pois para este arquivo não há a necessidade. As classes desenvolvidas no projeto são: calibracao, manual, automatica, corcalibrada, janela-principal e tstudent. Já a classe qcustomplot é um componente para auxílio em plotagem de gráficos e visualização de dados(29). Para melhor entendimento da interação entre as classes a figura 3.2 trás o diagrama de classes do projeto.

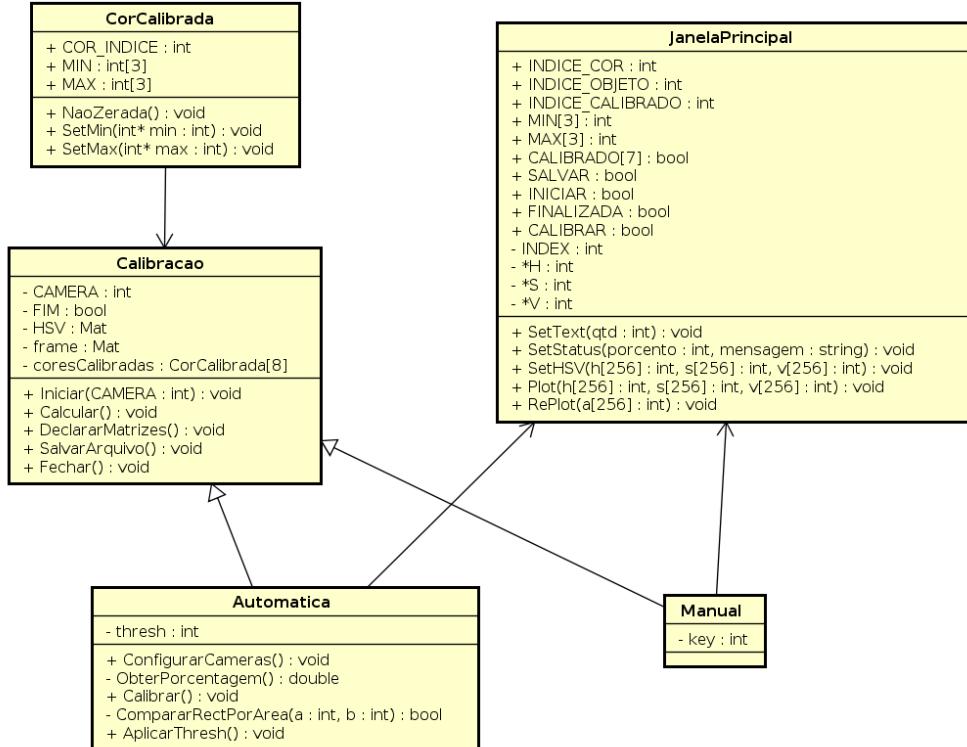


Figura 3.2: Diagrama de Classes do projeto

### 3.1.2 Classes

**main** esta é a classe executavel do sistema, ela inicia o programa e em seguida chama a classe de interação grafica **janelaprincipal**

**janelaprincipal** classe que faz a interação com o usuário e que de acordo com esta interação seleciona o tipo de calibração, e seus parâmetros, para então ser feita a análise dos pixels

**calibracao** classe "pai" que contém os métodos e variáveis que serão usadas por ambas as classes **manual** e **automatica**

**manual** classe que contém os métodos, cálculos e variáveis necessárias para a calibração manual

**automatica** classe que contém os métodos, cálculos e variáveis necessárias para a calibração automática

**corcalibrada** classe que salva o índice da cor já calibrada e seu intervalo de valores

**tstudent** esta é a classe que faz o cálculo probabilístico conhecido com TdeStudent

## 3.2 Fluxo do Sistema

O sistema possui um fluxo principal e dois subfluxos de acordo com o tipo de calibração escolhida. A Figura 3.3 mostra o fluxo principal do sistema.

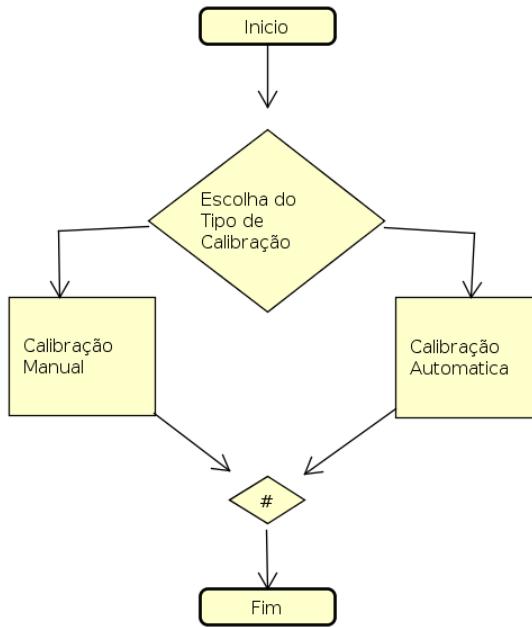


Figura 3.3: Diagrama de Fluxo

O fluxo principal do sistema consiste na apresentação da **interface gráfica** ao usuário. A **interface gráfica** por sua vez oferece as duas possibilidades de calibração: Calibração Manual e Calibração Automática. De acordo com o tipo de calibração escolhido o sistema inicia um subfluxo. Após a execução de todo subfluxo o sistema é finalizado.

### 3.2.1 Fluxo de Calibração Manual

O fluxo de calibração manual é iniciado somente se a camera estiver disponivel. Após a camera ser inicializada(1) o sistema espera pela seleção do objeto(2) o qual terá seus pixels calculados para gerar os valores HSV. Com o objeto selecionado o usuário escolhe então a cor(4), na opção de escolha de cor, e calibrar. A área selecionada é então analizada e os valores de cada pixel calculados analizando seu HSV(3). O usuário então seleciona os valores que considera satisfatórios(5). Enquanto houverem objetos a serem calibrados(6) o sistema repete esta mesma rotina, quando todos os objetos já tiverem sido calibrados, um arquivo com os valores é gerado(7) e o usuário finaliza o sistema.

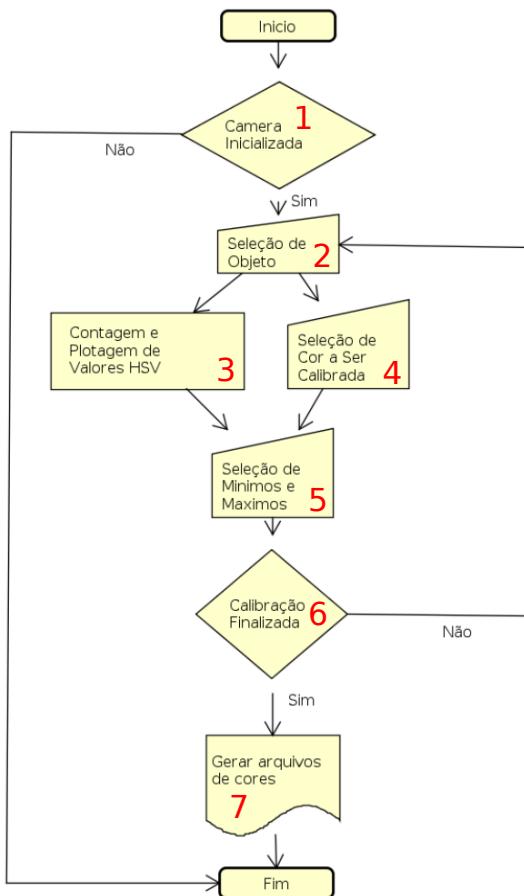


Figura 3.4: Diagrama de Fluxo Manual

### 3.2.2 Fluxo de Calibração Automatica

O fluxo de calibração automatica possui o minimo possível de interação com o usuário. Neste fluxo o sistema faz automaticamente a detecção de objetos e utilizando a probabilidade matematica conhecida com T de Student verifica o tamanho de cada objeto encontrado para gerar um limite considerado o tamanho que os objetos que devem ser encontrados terão, nesse caso as etiquetas de cores dos robôs e só então analizar os valores e calcular os valores minimos e maximos de HSV automaticamente. O fluxo inicia somente caso a camera esteja disponivel(1), apos a sua inicialização é feita a configuração da camera(2),

enquadramento do tamanho correto e correção de brilho e luminosidade. Uma vez que a camera está configurada o sistema inicia a deteção de objetos e a validação dos objetos(3) que estão no tamanho correto. Apos deixar somente os objetos corretos no sistema, os pixeis de cada um são varridos e seu intervalo HSV encontrado(4). Os objetos e cores encontrados ficam disponíveis para o usuario pra esse fazer a assimilação entre os objetos e as cores corretas(5), aps intervalos corretos já tiverem sido calibrados, um arquivo com os valores é gerado(6) e o usuario finaliza o sistema.

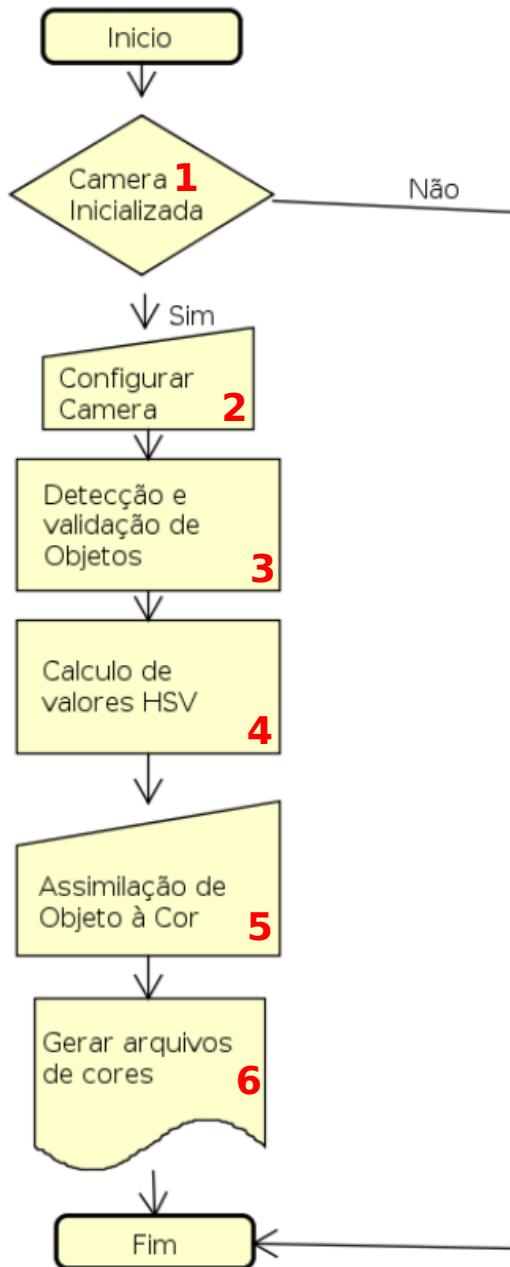


Figura 3.5: Diagrama de Fluxo Automatico

Nas sessões à seguir explicarei detalhadamente cada processo da calibração automatica

## Configuração de Camera

Antes de ser feito o processo de calibração são necessarias duas configurações: Constraste e Brilho e o Recorte de Imagem. A configuração de contraste e brilho utiliza o metodo *convertTo* da biblioteca *OpenCV* e é utilizada para o melhoramento da imagem antes da detecção dos objetos, a utilização completa fica da seguinte maneira:

```
frameA.convertTo(frameA, -1, contrast_value / 50.0, brightness_value)
```

a função recebe quatro parametros: **frameA** que informa aonde sera salvo o resultado da conversão, **-1** que indica o tipo da matrix, ou numero de canais, da imagem a ser gerada, usa-se **-1** quando se deseja que se use os valores semelhantes aos da imagem da imagem original(30), **contrast\_value / 50.0** indica o valor de constraste, ou alpha, a ser usado para multiplicar os valores do pixel da imagem(30) e **brightness\_value** é o valor do brilho, ou beta, a ser adicionado à imagem.

Outra configuração feita é o Recorte de Imagem, onde utilizando a função *setMouseCallback* para possibilitar a interação do usuario na imagem por meio do mouse, sua utilização é dada da seguinte maneira:

```
cv::setMouseCallback(src_window, mouseHandler, 0);
```

onde **src\_windows** indica a janela na qual a função recebera a interação, **mouseHandler** indica a função na qual esta implementada a interação e **0** indica parametros opcionais, neste caso não usaremos nenhum então foi usado o numero 0. Dentro da função **mouseHandler** são identificados os pontos inicio e final da seleção na tela e utilizada a função *rectangle* para demarcar a seleção na tela. A utilização da função *rectangle* completa fica da seguinte maneira:

```
cv::rectangle(frameA, point1, point2, CV_RGB(255, 0, 0), 2, 5, 0);
```

a função rebece os parametros **frameA** indica a imagem na qual será demarcada a area selecionada, **point1** que é o ponto incial de seleção na imagem, **point2** que é o ponto final da seleção. **CV\_RGB(255, 0, 0)** que indica a cor da demarcação, **2** indicando a expressura da demarcação, **5** que significa o tipo de linha a ser utilizado na demarcação e **0** que é o numero de bits fracionarios. Após confirmada a escolha do tamanho da tela este é então salvo na variavel nomeada *tamanho*, está então sera usado durante todo o processo de calibração.

### Detecção e validação de Objetos

A detecção dos objetos a serem calibrados é dada pelo algoritmo de detecção de bordas de Canny. Como mais um recurso para eliminação de ruidos e melhoria da imagem antes de ser executado a detecção de objetos através da detecção de bordas é utilizado desfoque na imagem. O algoritmo de Canny já está implementado dentro da biblioteca OpenCV e com a seguinte usagem:

```
Canny(src_gray, canny_output, thresh, thresh * 3, 3);
```

O algoritmo de Canny utiliza por padrão imagem em padrões de cinza, sendo assim **src\_gray** é a imagem original transformada para escala de cinza. **canny\_output** será a imagem de saída da função. **thresh** e **thresh\*3** são os limites mínimos e máximos para considerar uma borda. **3** é o valor de abertura ou kernel, o valor 3 é utilizado como padrão.

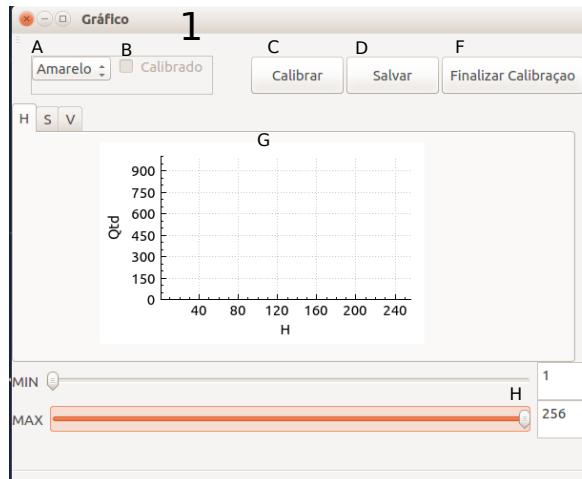
Apos o uso do algoritmo de Canny para detecção de bordas é necessário então fazer uso da função *findContours*, nativa no *OpenCV* para detecção dos contornos em si.

```
findContours(canny_output, contours, hierarchy, CV_RETR_EXTERNAL,  
CV_CHAIN_APPROX_SIMPLE, Point(0, 0))
```

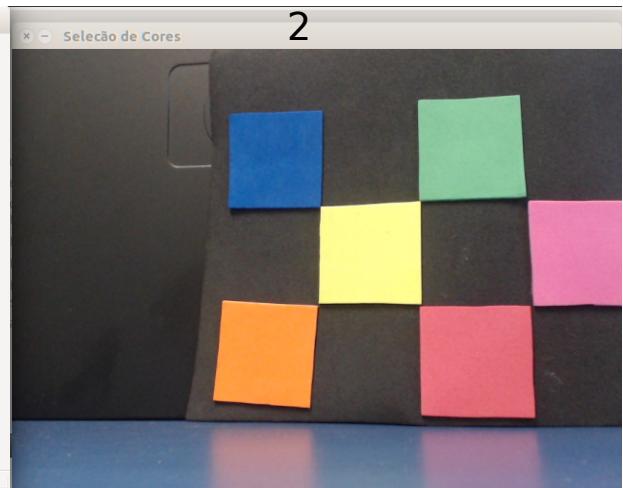
# Capítulo 4

## Aplicativo

### 4.1 Tela Principal



(a) Janela 1



(b) Janela 2

Figura 4.1: Janelas do Sistema: Janela 1 e Janela 2

A tela do sistema é formada por duas janelas. Janela 1 é a janela que recebe as interações do usuário, a Janela 2 é composta pela imagem obtida pela câmera, e para ser feita a escolha da cor. Na Janela 1 possui ações de escolha de cor via Combo Box(A), um Check Box(B) que informa se a cor já foi calibrado ou não. Botões de Calibrar(C), que é usado após a seleção da cor para a geração do gráfico, Salvar(D), que é usado após a seleção dos valores para que estes sejam salvos na memória do aplicativo, e Finalizar Calibração(F) que irá salvar os valores em arquivo. Uma área de gráfico (G) onde são mostrados os valores de ocorrência de H, S e V, cada um em uma aba diferente. A Janela 1 ainda possui uma área de seleção dos valores(H), com região MIN e MAX que possui tanto Sliders quanto Área de texto para seleção dos valores mínimos e máximos.

## 4.2 Seleção do Objeto Colorido

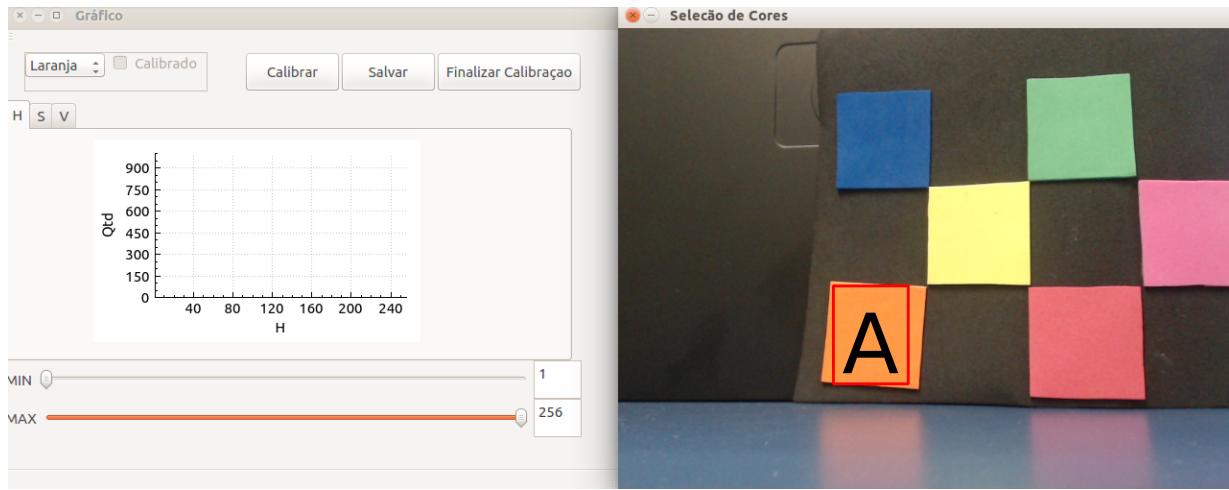


Figura 4.2: A seleção do ponto com a cor, é obtido pela interação do usuário.

A seleção das cores é feita selecionando, com o ponteiro do mouse clicando na área inicial e arrastando até a área final do objeto correspondente a cor. Um exemplo de seleção de cor ocorre na Figura 4.2 em A onde é selecionada a cor Laranja. Após seleção da cor é necessário apertar no botão Calibrar para assim ser feito os cálculos dos valores HSV dos pixels e ser gerado o gráfico.

## 4.3 Geração de Gráfico

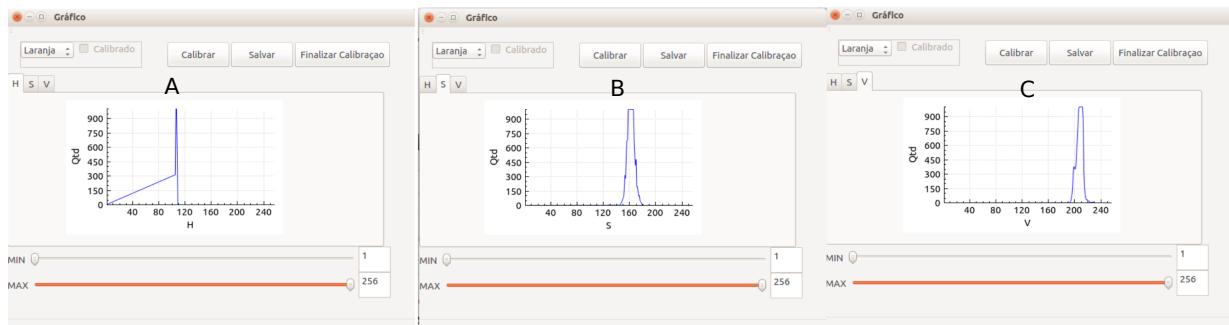


Figura 4.3: Gráfico gerado após seleção dos pontos de cor.

Quando se aperta o botão Calibrar são gerados os 3 Gráficos de ocorrência de valor de H(A), S(B) e V(C), um em cada aba. No gráfico são vistos quais os valores que possuem mais ocorrência, para assim ser feita a seleção.

## 4.4 Seleção de Minimos e Maximos

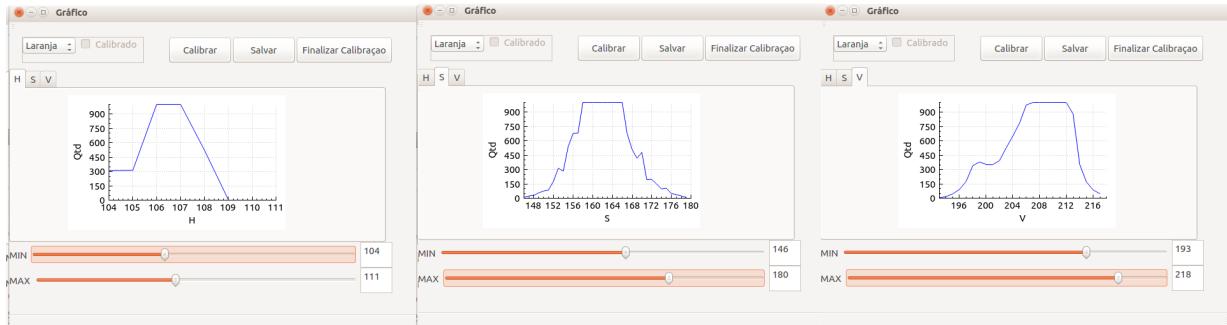


Figura 4.4: Gráfico após escolhas de mínimos e máximos.

Usando os Sliders ou Entrada de Texto(explicados na sessão 4.1) são selecionados os valores mínimos e máximos para H, S e V. Durante a seleção dos valores o gráfico é atualizado para melhor visualização das ocorrências.

## 4.5 Arquivo Final

Arquivo gerado apos valores serem selecionados e salvos. Para cada cor selecionado são feitas duas linhas, a primeira contendo os valores mínimos e a segunda os valores máximos, no inicio de cada linha há o índice da cor.

```
cores.arff (~/Dropbox/TCC/Codigos/QT/build-Tutorial-Desktop_Qt_5_5_1_0)
Open Save Undo Cut Copy Paste Plain Text Tab Width: 8 Ln 16, Col 10 INS
cores.arff x
1 0 : 0.0.0
2 0 : 0.0.0
3 1 : 0.0.0
4 1 : 0.0.0
5 2 : 0.0.0
6 2 : 0.0.0
7 3 : 104.171.251
8 3 : 109.195.255
9 4 : 0.0.0
10 4 : 0.0.0
11 5 : 0.0.0
12 5 : 0.0.0
13 6 : 0.0.0
14 6 : 0.0.0
15 7 : 0.0.0
16 7 : 0.0.0|
```

Figura 4.5: Arquivo com minimo e máximo dos valores HSV para cada cor.

# Capítulo 5

## Primeiros Resultados - Seleção Manual de Mínimos e Máximos

Neste capítulo são apresentados os resultados dos testes realizados.

A primeira etapa do projeto, já concluída, é a seleção manual de mínimos e máximos. Nessa etapa foi gerado uma imagem Threshold onde somente objetos que possuam seu HSV entre os valores calibrados apareçam.



Figura 5.1: Threshold gerado apos seleção manual.

# Bibliografia

1

2 HORVATH, M. In: .

3 MENDES, E. P.; MEDEIROS, A. A. D. Sistema de localização visual da equipe de futebol de robôs POTI-UFRN (versão 2008) na categoria very small size. In: . Salvador, Brasil: , c2008.

4 SPIEGEL, M. R. *Estatística*. McGraw-Hill do Brasil, 1974.

5 PENHARBEL, E. A.; DESTRO, R.; TONIDANDEL, F.; BIANCHI, R. A. Filtro de imagem baseado em matriz rgb de cores-padrão para futebol de robôs. *Submetido ao I Encontro de Robótica Inteligente*, 2004.

6 DA ROSA, J. F. *Construção de um time de futebol de robôs para a categoria ieee very small size soccer*. Dissertação de Mestrado - FACULDADE DE DUCAÇÃO TECNOLÓGICA DO ESTADO DO RIO DE JANEIRO.

7 SIRLAB. In: .

8 ALBUQUERQUE, M.; ALBUQUERQUE, M. Processamento de imagens: métodos e análises. *Revista de Ciência e Tecnologia*, Rio de Janeiro, p. 10–22, 2001. Centro Brasileiro de Pesquisas Físicas MCT.

9 GONZALEZ, R.; WOODS, R. *Digital image processing*. Pearson/Prentice Hall, 2008.

10 VIOLA, P.; JONES, M. Rapid object detection using a boosted cascade of simple features. In: . c2001. v. 1. p. I–511.

11 NASCIMENTO, M. C. *Detecção de objetos em imagens*. Dissertação de Mestrado - Centro de Informática, Universidade Federal de Pernambuco.

12 ROTH, P. M.; WINTER, M. Survey of appearance-based methods for object recognition. *Inst. for Computer Graphics and Vision, Graz University of Technology, Austria, Technical Report ICGTR0108 (ICG-TR-01/08)*, 2008.

13 AMIT, Y.; FELZENZWALB, P. Object detection. In: IKEUCHI, K. (Ed.) *Computer Vision, A Reference Guide*. New York, NY, USA: Springer, 2014. v. 2, p. 537–542.

14 ULUSOY, I.; BISHOP, C. M. Generative versus discriminative methods for object recognition. In: . CVPR. Washington, DC, USA: IEEE Computer Society, c2005. p. 258–265.

- 15 WANGENHEIM, A. Von. encontrando a linha divisória: Detecção de borda. *Departamento de Informática e Estatística-Universidade Federal de Santa Catarina, 2013a*, v. 16.
- 16 CANNY, J. A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. PAMI-8, n. 6, p. 679–698, Nov 1986.
- 17 DO VALE, G. M.; POZ, A. P. D. O processo de detecção de bordas de canny: Fundamentos, algoritmos e avaliação experimental. In: BERGIN, T. J.; GIBSON, R. G. (Eds.) *Simpósio Brasileiro de Geomática*. 2002. p. 292–303.
- 18 SOUTO, R. P. *Segmentação de imagem multiespectral utilizando-se o atributo matiz*. 2003. Dissertação de Mestrado - INPE, São José dos Campos, 2003.
- 19 ROCHA, J. C. Cor luz, cor pigmento e os sistemas rgb e cmy. *Revista Belas, Centro Universitário Belas Artes de São Paulo*, v. 3, 2010.
- 20 LEÃO, A. C.; DE ALBUQUERQUE ARAÚJO, A.; SOUZA, L. A. C. Implementação de sistema de gerenciamento de cores para imagens digitais. In: TEIXEIRA, A. C.; BARRÉRE, E.; ABRÃO, I. C. (Eds.) *Web e multimídia: desafios e soluções*. PUC Minas, 2005.
- 21 MARTINS, D. L.; MENDES, E. P.; LINS, F. C. A.; ARAÚJO, M. V. D.; MEDEIROS, A. A. D.; ALSINA, P. J. A versão 2007 da equipe poti de futebol de robôs. In: . c2007.
- 22 CULJAK, I.; ABRAM, D.; PRIBANIC, T.; DZAPO, H.; CIFREK, M. A brief introduction to opencv. In: . c2012. p. 1725–1730.
- 23 STROUSTRUP, B. A history of c++: 1979–1991. In: BERGIN, T. J.; GIBSON, R. G. (Eds.) *History of programming languages — II*. Addison-Wesley, 1996.
- 24 FLUMINENSE, U. F. Tabela t: Distribuição de t-student segundo os graus de liberdade e uma dada probabilidade num teste bicaudal. Epidemiologia, curso de Medicina, Acessado 01/04/2016 10:00.
- 25 DO RIO GRANDE DO NORTE, U. F. História da estatística. Acessado 31/03/2016 14:50.
- 26 COSTA, A. H. R.; PEGORARO, R. Construindo robôs autônomos para partidas de futebol: o time guaraná. *SBA Controle & Automação*, v. 11, n. 03, p. 141–149, 2000.
- 27 KITANO, H.; ASADA, M.; KUNIYOSHI, Y.; NODA, I.; OSAWA, E.; MATSUBARA, H. Robocup: A challenge problem for ai. *AI magazine*, v. 18, n. 1, p. 73, 1997.
- 28 PENHARBEL, E. A.; MARTINS, M. F.; FAZOLIN, A.; GURZONI JR, J. A.; EDUARDO, H.; DEBIA, T.; PEREIRA, V. F.; DESTRO, R. C.; TONIDANDEL, F.; BIANCHI, R. A. Time de futebol de robôs y04 do centro universitário da fei.
- 29 EICHHAMMER, E. Qcustomplot. Acessado 28/06/2016 22:09.
- 30 ITSEEZ. Opencv. Acessado 29/06/2016 16:53.